

Univerzita Jana Evangelisty Purkyně
v Ústí nad Labem
Přírodovědecká fakulta



Analýza spotřeby energie s využitím metod
strojového učení

BAKALÁŘSKÁ PRÁCE

Vypracoval: Ondřej Thomas

Vedoucí práce: Kubera Petr, RNDr. Ph.D.

Studijní program: Aplikovaná informatika

Studijní obor:

ÚSTÍ NAD LABEM 2025

Namísto žlutých stránek vložte digitálně podepsané zadání kvalifikační práce poskytnuté vedoucím katedry.

Zadání musí zaujímat právě dvě strany.

Zadání je nutno vložit jako PDF pomocí některého nástroje, který umožňuje editaci dokumentů (se zachováním elektronického podpisu).

V Linuxe lze například použít příkaz `pdftk`.

Prohlášení

Prohlašuji, že jsem tuto bakalářskou práci vypracoval samostatně a použil jen pramenů, které cituji a uvádím v přiloženém seznamu literatury.

Byl jsem seznámen s tím, že se na moji práci vztahují práva a povinnosti vyplývající ze zákona č. 121/2000 Sb., ve znění zákona č. 81/2005 Sb., autorský zákon, zejména se skutečností, že Univerzita Jana Evangelisty Purkyně v Ústí nad Labem má právo na uzavření licenční smlouvy o užití této práce jako školního díla podle § 60 odst. 1 autorského zákona, a s tím, že pokud dojde k užití této práce mnou nebo bude poskytnuta licence o užití jinému subjektu, je Univerzita Jana Evangelisty Purkyně v Ústí nad Labem oprávněna ode mne požadovat přiměřený příspěvek na úhradu nákladu, které na vytvoření díla vynaložila, a to podle okolností až do jejich skutečné výše.

V Ústí nad Labem dne 26. listopadu 2025

Podpis:

Děkuji vedoucímu bakalářské práce Petru Kuberovi, RNDr. Ph.D. za jeho odborné vedení a praktické podněty, které výrazně přispěly k analýze dat, hledání efektivních řešení a k celkovému úspěšnému dokončení bakalářské práce.

Abstrakt:

Bakalářská práce se zabývá srovnáním open-source a komerčních nástrojů pro vizualizaci a analýzu dat, datové sklady a OLAP technologie s cílem zhodnotit jejich vhodnost pro využití v datové platformě Portabo. V praktické části byla realizována implementace několika variant datových řešení, zahrnujících kombinace databázových systémů MSSQL, MariaDB, ClickHouse a PostgreSQL s nástroji Power BI, Superset a Cube.js. Bylo provedeno testování výkonu, analýza technických požadavků, nároků na uživatelské dovednosti a srovnání ekonomických aspektů provozu. Výsledkem práce je komplexní přehled výhod a nevýhod jednotlivých přístupů, měření jejich efektivity při zpracování velkých objemů dat a doporučení optimálního řešení pro organizace usilující o efektivní datovou analytiku bez nutnosti vysoké IT expertizy.

Klíčová slova: Business Intelligence, datové sklady, olap, vizualizace dat, Portabo

ENERGY CONSUMPTION ANALYSIS USING MACHINE LEARNING METHODS

Abstract:

This bachelor's thesis focuses on the comparison of open-source and commercial tools for data visualization and analysis, data warehouses, and OLAP technologies, with the aim of evaluating their applicability within the Portabo data platform. In the practical part, several data architecture variants were implemented, combining database systems such as MSSQL, MariaDB, ClickHouse, and PostgreSQL with visualization tools including Power BI, Superset, and Cube.js. The analysis covers performance testing, technical requirements, user skill demands, and economic aspects of operation. The outcome of the thesis is a comprehensive overview of the advantages and limitations of both open-source and commercial solutions, performance evaluation on large data volumes, and recommendations for organizations seeking efficient data analytics without requiring extensive IT expertise.

Keywords: Business Intelligence, data warehouses, OLAP, data visualization, Portabo

Obsah

Úvod

1 Teoretická část

1.1 Úvod do problematiky analýzy spotřeby energie

Energetická spotřeba představuje jeden z klíčových ukazatelů fungování moderní společnosti. Rostoucí podíl obnovitelných zdrojů, jejichž výroba je proměnlivá a obtížně predikovatelná, klade stále vyšší nároky na detailní sledování, ukládání a analýzu energetických dat. Jak zdůrazňují Sterner a Stadler (2019), právě schopnost porozumět spotřebě energie a efektivně ji řídit je nezbytným předpokladem pro úspěšnou transformaci energetických systémů směrem k udržitelnosti.

Význam a využití energetických dat

Energetická data představují základní informační zdroj pro pochopení a řízení spotřeby energie v různých kontextech, od jednotlivých domácností přes průmyslové podniky až po celé městské aglomerace. Jejich detailní sběr a analýza umožňuje nejen sledovat aktuální stav, ale také předvídat budoucí vývoj a přijímat kvalifikovaná rozhodnutí. Sterner a Stadler (2019) popisují význam a využití energetických dat, který lze dále charakterizovat v souvislosti s:

Optimalizací provozu

- **Snížení nákladů:** detailní data o spotřebě umožňují identifikovat neefektivní procesy, nadměrné ztráty nebo energeticky náročné zařízení.
- **Zvýšení efektivity:** na základě analýzy lze navrhnout opatření, jako je lepší regulace vytápění, optimalizace výrobních cyklů nebo využívání levnějších tarifů.
- **Praktický příklad:** v administrativních budovách lze díky datům nastavit inteligentní řízení osvětlení a klimatizace podle skutečné obsazenosti.

Predikcí zatížení sítí

- **Stabilita elektrické soustavy:** energetická data umožňují provozovatelům sítí předvídat špičky v odběru a přizpůsobit výrobu či distribuci.
- **Řízení rizik:** včasná predikce zatížení pomáhá předcházet výpadkům nebo nutnosti využívat drahé záložní zdroje.
- **Praktický příklad:** během zimních večerů lze na základě historických dat předvídat zvýšenou spotřebu a připravit odpovídající kapacitu.

Integrací obnovitelných zdrojů

- **Vyrovňávání rozdílů mezi výrobou a spotřebou:** obnovitelné zdroje (solární, větrné) jsou proměnlivé, proto je nutné jejich produkci sladit s aktuální poptávkou.
- **Podpora akumulace:** energetická data pomáhají rozhodovat, kdy ukládat energii do baterií či jiných úložišť a kdy ji uvolnit.
- **Praktický příklad:** solární elektrárna může díky predikci spotřeby a výroby lépe plánovat dodávky do sítě a minimalizovat ztráty.

Podporou rozhodování

- **Domácnosti:** spotřebitelé mohou sledovat svou spotřebu v reálném čase a přizpůsobit chování (např. využívat spotřebiče v době levnější elektřiny).
- **Podniky:** firmy využívají data pro plánování výroby, investic do úsporných technologií nebo pro certifikace v oblasti udržitelnosti.
- **Městské celky a státy:** energetická data slouží jako podklad pro strategické rozhodování, od plánování infrastruktury po tvorbu energetických politik.
- **Praktický příklad:** město může na základě analýzy spotřeby rozhodnout o investici do chytrého osvětlení nebo podpory komunitní energetiky.

Sterner a Stadler (2019) ve své *Handbook of Energy Storage* zdůrazňují, že energetická data jsou klíčovým prvkem moderní energetiky. Podle nich umožňují optimalizovat provoz, předvídat zatížení sítí, integrovat obnovitelné zdroje a podporovat rozhodování na všech úrovních – od domácností až po národní politiky. V jejich pojetí jsou data základním předpokladem pro efektivní fungování energetických úložišť a pro stabilitu celého systému.

Vedle tohoto systémového pohledu se k tématu vyjadřuje také Géron (2019) ve své knize *Hands-On Machine Learning with Scikit-Learn, Keras & TensorFlow*. Ten zdůrazňuje především metodologickou stránku. Podle Gérona jsou energetická data typickým příkladem časových řad, které lze analyzovat pomocí strojového učení. Jejich význam je právě v tom, že umožňují:

- **Optimalizaci provozu** prostřednictvím regresních modelů, které odhalují vztahy mezi faktory spotřeby.
- **Predikci zatížení sítí** díky neuronovým sítím (RNN, LSTM, GRU), schopným zachytit dlouhodobé závislosti.
- **Integraci obnovitelných zdrojů** díky modelům, které zvládají pracovat s nestabilními a nelineárními daty.
- **Podporu rozhodování** na základě interpretovatelných modelů, které vysvětlují, proč k určité predikci došlo.

Zatímco Sterner a Stadler tedy akcentují energetický systém a jeho stabilitu, Géron se soustředí na technické nástroje strojového učení, které dávají energetickým datům praktickou hodnotu.

Oba přístupy se vzájemně doplňují: bez kvalitních dat by nebylo možné efektivně řídit energetické úložiště, a bez metod strojového učení by nebylo možné tato data smysluplně analyzovat a využít pro predikci či klasifikaci.

Tabulka č. 1 poskytuje informace, které jsou zaměřeny na komparativní pohled v souvislosti s významem energetických dat podle Sternera a Stadlera a Gérona.

Autor	Hlavní zaměření	Význam dat	Relevance
Sterner & Stadler (2019) – Handbook of Energy Storage	Energetické systémy, ukládání energie, integrace do sítí	Energetická data jsou klíčová pro optimalizaci provozu, predikci zatížení sítí, integraci obnovitelných zdrojů a podporu rozhodování. Bez nich nelze efektivně řídit úložiště ani zajistit stabilitu systému.	Poskytují systémový rámec – ukazují, že data nezbytná pro řízení celé energetické soustavy.
Aurélien Géron (2019) – Hands-On Machine Learning with Scikit-Learn, Keras & TensorFlow	Strojové učení, analýza časových řad, predikce	Energetická data jsou typickým příkladem časových řad, které lze analyzovat ML metodami. Umožňují regresní analýzu (optimalizace), predikci pomocí LSTM/RNN (zatížení sítí), modelování nestabilních dat (obnovitelné zdroje) a interpretovatelné rozhodování.	Přináší metodologický rámec – ukazuje, jak krátké ML techniky aplikovat na praktická data.

Zdroj: Vlastní zpracování dle Sterner a Stadler (2019) a Géron (2019)

Komparace ukazuje, že Sterner a Stadler poskytují rámec, proč jsou energetická data důležitá pro fungování celé soustavy, zatímco Géron nabízí nástroje, jak tato data prakticky analyzovat. Spojením obou perspektiv vzniká komplexní pohled, který je pro tuto práci klíčový: energetická data mají nejen systémový význam, ale i metodologickou hodnotu pro jejich zpracování pomocí strojového učení.

Současné metody měření spotřeby

Techniky měření spotřeby energie prošly v posledních dekáдах zásadní evolucí, která odráží širší transformaci energetických systémů směrem k digitalizaci a inteligentnímu řízení. Zatímco tradiční indukční elektroměry poskytovaly pouze kumulativní údaje o odběru, současné digitální a chytré měřicí technologie umožňují detailní monitorování spotřeby v reálném čase, a to s vysokou granularitou a možností obousměrné komunikace. Tyto sofistikované systémy nejenže zpřesňují samotné měření, ale zároveň otevírají prostor pro pokročilé analytické postupy, predikci zatížení a integraci obnovitelných zdrojů. V následující podkapitole se proto zaměříme na současné metody měření spotřeby, jejich technické principy a význam pro efektivní řízení energetických procesů.

Publikace *The History of the Electricity Meter* od Synergy BV (2006) ukazuje, že vývoj měřicích technologií prošel zásadní proměnou od jednoduchých indukčních elektroměrů až po dnešní digitální a chytré systémy. Zatímco původní přístroje poskytovaly pouze kumulativní údaje o spotřebě, současné metody umožňují detailní sledování odběru v reálném čase, obousměrnou komunikaci s

distribuční sítě a integraci do konceptu inteligentních sítí (smart grids). Tyto moderní technologie tak nejen zpřesňují samotné měření, ale stávají se klíčovým zdrojem dat pro optimalizaci provozu, predikci zatížení a podporu rozhodování na různých úrovních energetického systému.

Vývoj metod měření spotřeby energie představuje klíčovou součást širší transformace energetických systémů. Od prvních mechanických elektroměrů až po dnešní sofistikované chytré technologie se postupně měnila nejen přesnost měření, ale i samotný charakter práce s daty. Současné přístroje již neslouží pouze k odečtu spotřeby, nýbrž se stávají aktivním prvkem inteligentních sítí, které umožňují detailní monitoring, obousměrnou komunikaci a pokročilé analytické využití. Následující přehled ukazuje hlavní etapy tohoto vývoje a jejich význam pro současnou praxi [Synergy2006].

1. Od mechanických k elektronickým měřičům

Tradiční indukční elektroměry s rotujícím kotoučem byly po desetiletí standardem, avšak poskytovaly pouze kumulativní údaje o spotřebě. Přechod k elektronickým měřičům znamenal zásadní kvalitativní posun – tyto přístroje dokázaly měřit s vyšší přesností a ukládat data v digitální podobě, čímž otevřely cestu k jejich systematické analýze.

2. Digitální elektroměry

Moderní digitální měřiče umožňují detailní časové záznamy spotřeby, nikoli jen souhrnné hodnoty. Spotřebu lze sledovat v různých intervalech (hodinových, minutových), což poskytuje podklad pro hlubší analýzu průběhu odběru a identifikaci vzorců chování.

3. Chytré elektroměry (Smart Meters)

Současný trend směřuje k chytrým měřičům, které jsou schopné obousměrné komunikace s distribuční sítí. Tyto přístroje nejen měří, ale také odesílají data v reálném čase a přijímají pokyny, například k omezení odběru v době špičky. Jsou klíčovým prvkem konceptu smart grids, tedy inteligentních sítí, které dynamicky reagují na poptávku a výrobu.

4. Rozšířené funkce

Současné měřiče dokáží sledovat nejen spotřebu, ale i parametry kvality energie – napětí, proud, účinník či harmonické složky. Díky tomu mohou provozovatelé sítí i spotřebitelé lépe porozumět chování systému a včas odhalovat anomálie.

5. Význam pro praxi

Moderní metody měření se stávají datovým základem pro optimalizaci provozu budov a zařízení, predikci zatížení sítí, integraci obnovitelných zdrojů i strategické rozhodování na úrovni domácností, podniků a států. Nejde tedy jen o technické vylepšení, ale o zásadní kvalitativní skok: od jednoduchého odečtu k inteligentnímu monitoringu a obousměrné komunikaci. Energetická data se díky tomu stávají klíčovým zdrojem pro moderní řízení energetických procesů [Synergy2006].

Publikace *The History of the Electricity Meter* od Synergy BV (2006) ukazuje, že vývoj měřicích technologií prošel zásadní proměnou – od tradičních indukčních elektroměrů poskytujících pouze kumulativní údaje až po dnešní digitální a chytré systémy schopné obousměrné komunikace a

detailního monitoringu spotřeby. Tento technologický rámec potvrzuje i [KhanWyrwa2024], kteří ve své studii *A Survey of Quantitative Techniques in Electricity Consumption—A Global Perspective* zdůrazňují, že právě moderní metody měření spotřeby energie představují datový základ pro aplikaci pokročilých kvantitativních technik. Podle nich chytré elektroměry umožňují využití statistických modelů časových řad i metod strojového a hlubokého učení, což otevírá cestu k predikci zatížení, detekci anomálií a optimalizaci provozu.

Zatímco Synergy BV akcentuje historickou evoluci měřičů a jejich technické schopnosti, Khan a Wyrwa ukazují, jak se tyto technologie stávají klíčovým zdrojem dat pro analytické postupy a strategické rozhodování. Společně tak oba zdroje potvrzují, že současné metody měření spotřeby nejsou jen technickým vylepšením, ale zásadním kvalitativním skokem, který propojuje technologii s datovou analýzou a praktickým řízením energetických systémů.

Současné metody měření spotřeby

Techniky měření spotřeby energie prošly v posledních dekáдах zásadní evolucí, která odráží širší transformaci energetických systémů směrem k digitalizaci a inteligentnímu řízení. Zatímco tradiční indukční elektroměry poskytovaly pouze kumulativní údaje o odběru, současné digitální a chytré měřicí technologie umožňují detailní monitorování spotřeby v reálném čase, a to s vysokou granularitou a možností obousměrné komunikace. Tyto sofistikované systémy nejenže zpřesňují samotné měření, ale zároveň otevírají prostor pro pokročilé analytické postupy, predikci zatížení a integraci obnovitelných zdrojů. V následující podkapitole se proto zaměříme na současné metody měření spotřeby, jejich technické principy a význam pro efektivní řízení energetických procesů.

Publikace *The History of the Electricity Meter* od Synergy BV (2006) ukazuje, že vývoj měřících technologií prošel zásadní proměnou od jednoduchých indukčních elektroměrů až po dnešní digitální a chytré systémy. Zatímco původní přístroje poskytovaly pouze kumulativní údaje o spotřebě, současné metody umožňují detailní sledování odběru v reálném čase, obousměrnou komunikaci s distribuční sítí a integraci do konceptu inteligentních sítí (smart grids). Tyto moderní technologie tak nejen zpřesňují samotné měření, ale stávají se klíčovým zdrojem dat pro optimalizaci provozu, predikci zatížení a podporu rozhodování na různých úrovních energetického systému.

Přístroje pro měření spotřeby energie

Ozoh et al. (2019) ukazují, že současné metody měření spotřeby energie zahrnují nejen klasické elektroměry, ale i zařízení na úrovni jednotlivých spotřebičů a pokročilé průmyslové analyzátory. Důraz kladou na to, že moderní přístroje poskytují detailní a víceúrovňová data, která lze využít pro optimalizaci spotřeby, detekci anomálií a integraci do inteligentních sítí.

Tabulka 2 – Přístroje pro měření spotřeby energie podle Ozoh et al. Přehled uvedených přístrojů ukazuje, že současné metody měření spotřeby energie se vyznačují vysokou variabilitou – od tradičních elektroměrů přes digitální systémy až po sofistikované chytré technologie a průmyslové analyzátory. Společným jmenovatelem je posun od pouhého odečtu k detailnímu

Typ zařízení	Charakteristika	Výhody	Nevýhody	Typické využití
Tradiční elektroměry (mechanické/indukční)	Rotující kotouč, mechanický odečet, měří kumulativní spotřebu	Jednoduchost, dlouhá životnost	Nízká přesnost, žádná možnost detailní analýzy	Domácnosti, podniky v minulosti
Digitální elektroměry	Elektronické zpracování, displej, ukládání dat v digitální podobě	Vyšší přesnost, snadný odečet	Omezená interaktivita	Moderní domácnosti, podniky
Chytré elektroměry (Smart Meters)	Obousměrná komunikace, reálný čas, integrace do smart grids	Detailní časové řady, vzdálený odečet, podpora řízení spotřeby	Vyšší pořizovací cena, nutnost infrastruktury	Inteligentní síťové celky, podniky
Plug-in měřiče spotřeby (appliance-level meters)	Malé přístroje zapojené mezi zásuvku a spotřebič	Snadné použití, detailní měření konkrétního zařízení	Omezené na jednotlivé spotřebiče	Domácnosti, měření spotřeby
Pokročilé průmyslové analyzátory energie	Sledují spotřebu i kvalitu energie (napětí, proud, účinník, harmonické složky)	Komplexní monitoring, odhalování anomálií	Vyšší cena, složitější instalace	Průmyslové velké budovy
Bezdrátové monitorovací systémy (IoT senzory)	Síť senzorů propojených bezdrátově, sběr dat v reálném čase	Flexibilita, možnost integrace do chytrých systémů	Potřeba robustní infrastruktury, kybernetická bezpečnost	Smart home, průmyslové aplikace

Zdroj: Vlastní zpracování dle Ozoh et al. (2019)

monitoringu a obousměrné komunikaci, která poskytuje datový základ pro optimalizaci, predikci i strategické rozhodování. Tyto přístroje tak potvrzují, že měření spotřeby se stalo nedílnou součástí moderního energetického managementu.

1.2 Použití metod strojového učení pro analýzu časových řad

Energetická data jsou klíčovým prvkem moderní energetiky. Umožňují nejen sledovat spotřebu, ale především ji řídit, předvídat a optimalizovat. V kontextu strojového učení mají zásadní význam, protože poskytují časové řady, na jejichž základě lze klasifikovat objekty, predikovat budoucí spotřebu a navrhnout efektivní strategie pro integraci obnovitelných zdrojů [SternerStadler2019].

Pojem časové řady a její charakteristiky

Časové řady představují zvláštní typ dat, jejichž podstatou je sledování hodnot v čase. Na rozdíl od běžných statistických souborů, kde pořadí jednotlivých pozorování nehraje roli, zde časová posloupnost určuje význam i interpretaci. Každý záznam je výsledkem předchozího vývoje a současně ovlivňuje budoucí hodnoty, což z časových řad činí klíčový nástroj pro analýzu dynamických jevů, od ekonomických ukazatelů přes energetickou spotřebu až po demografické či klimatické procesy.

Prince (2023) tento rámec rozšiřuje tím, že časové řady označuje za typ sekvenčních dat, jejichž hlavní charakteristikou je vzájemná provázanost jednotlivých prvků. Právě tato závislost odlišuje časové řady od jiných datových struktur a vysvětluje, proč se staly středem zájmu moderních metod strojového učení. V následující části budou proto vymezeny jejich základní komponenty, které tvoří východisko pro pokročilé modelování a predikci.

Klasická statistická literatura vymezuje časové řady prostřednictvím jejich základních komponent – trendu, sezónnosti, cykličnosti a náhodné složky. Jak ukazují *Box a Jenkins (1976)* ve své metodologii modelování časových řad, právě identifikace těchto prvků je nezbytným předpokladem pro konstrukci vhodných predikčních modelů, zejména typu ARIMA. Podobně *Hamilton (1994)* zdůrazňuje, že rozlišení systematických a náhodných složek časové řady umožňuje lépe porozumět dynamice sledovaného jevu a oddělit dlouhodobé trendy od krátkodobých fluktuací. Tento rámec tvoří východisko pro pokročilé modelování a predikci, které se v současnosti stále častěji opírá o metody strojového učení a hlubokých neuronových sítí.

Prince (2023) dále zdůrazňuje, že časové řady jsou typickým příkladem sekvenčních dat, tedy dat, u nichž pořadí jednotlivých hodnot hraje zásadní roli. Na rozdíl od klasického statistického přístupu (Box–Jenkins, Hamilton), který pracuje s komponentami jako trend, sezónnost či cykličnost, *Prince* se soustředí na to, jak tyto závislosti mezi prvky zachytit pomocí metod hlubokého učení.

Rekurentní neuronové sítě (RNN) představují první architekturu schopnou pracovat se sekvenčními daty, tedy i s časovými řadami. Jejich princip spočívá v tom, že každý výstup závisí nejen na aktuálním vstupu, ale také na předchozím stavu sítě, což jim umožňuje uchovávat informaci o minulých hodnotách a využívat ji při predikci. *Prince (2023)* zdůrazňuje, že RNN dokáží zachytit krátkodobé závislosti mezi jednotlivými prvky sekvence, a proto se osvědčily při modelování jevů, kde hraje roli bezprostřední minulost. Zároveň však upozorňuje na jejich zásadní omezení: při práci s dlouhými sekvencemi dochází k postupnému vyhasínání gradientů během procesu učení, což vede k tomu, že síť „zapomíná“ vzdálenější kontext. Tento problém, známý jako *vanishing gradient*, výrazně omezuje schopnost RNN uchovávat dlouhodobé informace a činí je nevhodnými pro predikce, kde je nutné zohlednit trend či sezónní vzorce. Právě tato slabina otevřela cestu k vývoji pokročilejších architektur, jako jsou LSTM a GRU, které dokáží dlouhodobé závislosti zachytit mnohem efektivněji.

Na omezení klasických rekurentních neuronových sítí reaguje vývoj pokročilejších architektur, které dokáží uchovávat informace i přes dlouhé časové intervaly. *Prince (2023)* vysvětluje, že sítě typu Long Short-Term Memory (LSTM) zavádějí mechanismus tzv. bran, jež regulují tok informací. Díky nim může síť rozhodovat, které údaje si ponechá v paměti, které zapomene a které využije pro výpočet aktuálního výstupu. Tento princip umožňuje modelovat dlouhodobé závislosti, které jsou pro časové řady zásadní, například sezónní cykly nebo dlouhodobé trendy ve spotřebě energie. Podobně fungují i Gated Recurrent Units (GRU), které představují zjednodušenou variantu LSTM, avšak s obdobnou schopností pracovat s rozsáhlým kontextem. *Prince* zdůrazňuje, že právě tyto architektury se staly standardem pro predikci časových řad, protože dokáží překonat problém vyhasínajících gradientů a poskytují robustní rámec pro modelování komplexních dynamických procesů.

Na architektury LSTM a GRU navazuje další zásadní posun v práci se sekvenčními daty, modely typu *Transformer*. Prince (2023) zdůrazňuje, že tyto sítě opouštějí princip rekurence a místo toho využívají mechanismus pozornosti (*attention*), který umožňuje modelu dynamicky určovat, jakou váhu mají jednotlivé prvky sekvence vůči sobě navzájem. Díky tomu dokáží efektivně zachytit i velmi dlouhé závislosti, aniž by trpěly problémem vyhasínajících gradientů, který limitoval klasické RNN. Transformery tak poskytují flexibilní rámec, v němž lze modelovat komplexní vztahy mezi hodnotami časové řady, a to bez ohledu na jejich vzdálenost v čase. Prince ukazuje, že tato architektura se stala současným vrcholem v analýze sekvenčních dat a její využití se rychle rozšířilo z oblasti zpracování přirozeného jazyka do dalších domén, včetně predikce ekonomických ukazatelů, modelování energetické spotřeby či analýzy biologických signálů.

Vývoj metod hlubokého učení pro analýzu časových řad lze podle Prince (2023) chápat jako postupné překonávání limitů jednotlivých architektur. Rekurentní neuronové sítě (RNN) představovaly první krok, protože dokázaly zachytit krátkodobé závislosti mezi prvky sekvence. Je jejich slabinou však byla neschopnost uchovávat dlouhodobý kontext, způsobená problémem vyhasínajících gradientů. Na tuto nedostatečnost reagovaly architektury LSTM a GRU, které díky paměťovým mechanismům dokázaly uchovávat informace přes delší časové intervaly a staly se standardem pro predikci časových řad. Nejnovější posun pak představují modely typu Transformer, které opouštějí rekurenci a využívají mechanismus pozornosti. Ten umožňuje efektivně modelovat i velmi dlouhé sekvence a zachytit komplexní vztahy mezi hodnotami časové řady. Prince tak ukazuje, že vývoj od RNN přes LSTM/GRU až k Transformerům odráží snahu postupně překonávat omezení předchozích přístupů a vytvářet stále robustnější rámec pro analýzu sekvenčních dat

Popis perspektivních modelů strojového učení vzhledem k datům

Na přístupu Raschky (2017) je patrné, že perspektivnost modelů strojového učení je vždy podmíněna charakterem dat, s nimiž pracujeme. Zatímco klasické statistické metody vycházejí z předpokladu, že časové řady lze rozložit na komponenty jako trend, sezónnost, cykličnost a náhodnou složku (Box–Jenkins, Hamilton), Raschka ukazuje, že moderní neuronové architektury se učí tyto vzorce přímo z dat, bez nutnosti jejich explicitní dekompozice. V jeho pojetí se tak perspektivními stávají modely, které dokáží zachytit komplexní závislosti a adaptovat se na různé typy sekvenčních struktur – od textových dat přes biologické signály až po energetické či finanční časové řady.

Raschka zdůrazňuje, že architektury typu LSTM a GRU jsou vhodné tam, kde je nutné uchovávat dlouhodobý kontext, zatímco jednodušší RNN postačí pro krátké sekvence. Zároveň poukazuje na vývoj směrem k architekturám schopným paralelního zpracování rozsáhlých datových objemů, což se plně rozvinulo v modelech typu Transformer. Perspektivní modely strojového učení jsou tedy definovány nejen svou strukturou, ale především schopností přizpůsobit se povaze dat: krátké sekvence vyžadují odlišný přístup než dlouhé časové řady s výraznou sezónností či cykličností.

Spojení teoretického rámce Prince (2023) a praktického přístupu Raschky (2017) otevírá cestu k využití těchto modelů v oblasti klasifikace budov podle energetické spotřeby. Prince ukazuje,

že moderní architektury jako LSTM, GRU či Transformer dokáží zachytit komplexní sekvenční závislosti, zatímco Raschka zdůrazňuje jejich implementační rovinu a schopnost adaptace na různé typy dat. V kontextu energetiky to znamená, že modely mohou pracovat nejen s krátkodobými fluktuacemi spotřeby, ale i s dlouhodobými vzorci chování budov, sezónními cykly či vlivem externích faktorů. Perspektivní modely strojového učení se tak stávají nástrojem, který umožňuje klasifikovat budovy na základě jejich dynamických energetických profilů, nikoli pouze statických charakteristik. Tento přístup překonává tradiční statistické rámce a otevírá prostor pro sofistikovanou predikci i optimalizaci, což je klíčové pro městské plánování a udržitelný rozvoj.

Jak ukazují Ma et al. (2017), datová analýza představuje fundamentální prvek rozvoje inteligentních energetických sítí. Autoři zdůrazňují, že schopnost zpracovávat rozsáhlé senzorové záznamy, identifikovat dlouhodobé vzorce spotřeby a reagovat na proměnlivé podmínky je nezbytná pro efektivní řízení a optimalizaci energetických toků. V tomto smyslu se perspektivní modely strojového učení stávají nejen teoretickým či implementačním nástrojem, ale i praktickým pilířem inteligentní infrastruktury, která propojuje individuální spotřebitelské profily s celkovou stabilitou a udržitelností městských energetických systémů.

ně zpřehlednit, jak se architektury jako RNN, LSTM, GRU či Transformer adaptují na různé datové struktury

2 Praktická část

2.1 Analýza dostupných řešení

2.2 Přehled a srovnání existujících systémů pro určení charakteru objektů z energetické spotřeby

2.3 Návrh a implementace prototypu systému pro určení charakteru objektů z energetické spotřeby

2.4 Návrh vhodných příznaků z energetických dat

2.5 Vytvoření a trénování klasifikačního modelu

2.6 Testování a vyhodnocení výsledků

Podsekce

Podsekce se už používají méně často a běžně se vyskytují i dále nečleněné sekce. Nejsou číslovány a nejsou zobrazeny v obsahu. Rozsah by měl být alespoň dva odstavce.

Podpodsekce

Podpodsekce se používají jen velmi zřídka, typicky jen u kapitol či sekcí popisujících systémy s výraznou hierarchií. Tvořeny mohou být i jediným odstavcem (nikoliv však ale jedinou řádku, zde zvažte spíš použití definičního výčtu).

V šabloně je využita rodina písma *Libertinus* (odvozená z písma *Linux Libertine*) s výjimkou neproporcionálního písma, pro něž bylo zvoleno písmo *Source Code Pro*, které podporuje výrazně větší počet řezů (kurzíva tučné).

Standardní velikost písma kvalifikační práce je 12 bodů (přesněji řečeno tzv. pica bodů tj. 12/72 palce). Tato velikost však ve většině případů neodpovídá žádnému viditelnému rozměru písma (v klasické typografii je to výšky kuželky, na níž je umístěn vystouplý reliéf písma). Z tohoto důvodů se skutečná výška a především šířka písmen může u jednotlivých písmen viditelně lišit. To je problém, pokud se znaky různých písem vyskytují vedle sebe. Často se výrazněji liší například výška antikvy a neproporcionálního písma. V tomto případě je často nutné velikost neproporcionálních písem mírně zmenšit (tato šablona tak v případě využití XeTeXu nebo LuaTeXu činí automaticky). Optimální řádkování pro bakalářské práce je 1½ (použité i v této šabloně).

3 Praktická část

3.1 Návrh metodiky porovnání

3.2 Příprava dat a návrh datového skladu

3.3 Provedení srovnávací analýzy

3.4 Zhodnocení výsledků

4 Sazba ukázek kódu

Sazba ukázek kódu je klíčová pro bakalářské práce věnované implementaci nějaké aplikace či knihovny.

Základní zásady pro sazbu ukázek kódu:

- 1.

5 Citace

Citace tvoří jeden ze základních pilířů závěrečné práce. Platí zde základní pravidlo: pokud použijete jakoukoliv zdroj informací, pak je nutné tento zdroj citovat, tj. uvést příslušný zdroj.

Zdrojem je ve většině případů text, ale může to být i obrázek, audiovizuální materiál či ve speciálních případech i ústní sdělení. V případě informatických prací je častým zdrojem u zdrojový kód.

Informaci ze zdroje můžete použít dvěma různými způsoby:

- přímo převzít (u textů je to známé Ctrl-C, Ctrl-V)
- použít jako základ vlastního intelektuálního vytvoření (textu, grafiky, programu, apod.), tj. použijete jen informaci, ale její formu změníte.

První druh tzv. přímé citace by měli mít v informatických závěrečných pracích jen velmi omezený rozsah (méně než stránka), neboť jejich přínos pro hodnocení práce je diskutabilní. Přesto jsou však případy, kdy jsou vhodné:

1. matematické definice a tvrzení (věty, axiomy)
2. definice termínů z neinformatických oborů (např. společenských věd)
3. citace norem resp. standardů

Citace mají tři základní cíle:

1. určují, co je váš vlastní intelektuální přínos a co jste pouze převzali
2. pomáhají určovat primárního autora (resp. autory)
3. definují kontext vaší práce resp. mohou usnadňovat nalezení dalších souvisejících informací

Jakákoliv vědecká práce nevzniká na zelené louce a tak jsou citace její nezbytnou součástí. V rámci práce běžně navazujeme na existující výzkumy, projekty, technologie apod. Stejně tak se můžeme odkazovat na autority či s nimi polemizovat.

První dva cíle také úzce souvisejí s plagiátorstvím. Pokud v práci použijete myšlenku či údaj bez citování je vaše práce plagiátem. I když se to v obecném mínění vztahuje jen na přímé kopírování, není tomu tak. Přímé kopírování se jen snadněji vyhledává a prokazuje. Je také obtížnější jej kvantifikovat.

V případě přímého kopírování, jež není označeno jako přímá citace, postačuje i relativně malý rozsah (například věta, jeden obrázek, jedna procedura), aby byla práce označena jako plagiát.

Plagiát není možno obhájit a v případě většího rozsahu hrozí i vyloučení ze studia. Za přímé kopírování se považují i případy, kde je změna jen formální (změna slovosledu, náhrada synonym, zkrácení, vložení textové výplně, změna barvy či afinní transformace obrázku).

V případě převzetí myšlenky jde o zjevné plagiování, pokud je tato myšlenka důležitou částí práce (podílí se na splnění cílů).

To, že není plagiátorství odhaleno před obhajobou práce, není důkazem, že se nejedná o plagiát. Pokud je plagiátorství zjištěno později, může vám být odebrán titul i zpětně (a jak jste si jistě všimli, plagiátorství je běžně využíváno v politickém boji).

V každém případě si uvědomte, že plagiátorství je druh krádeže a že ani vy nechcete, aby někdo vaše myšlenky nebo dokonce váš text vydával za vlastní.

5.1 Označování citací

Označování citace má dvě části. Za prvé je nutno označit, jaká část práce je citací (rozsah) a jaký je původní zdroj.

Zdroj je vždy určen odkazem na bibliografický záznam, které jsou v případě bakalářské práce uvedeny v kapitole *Použité zdroje* na konci práce. Odkaz může mít různý tvar, ale preferovaný styl je uvedení čísla záznamu v hranatých závorkách. V případě použití našeho latexovského stylu stačí použít příkaz `\cite{id-zaznamu}`. V případě potřeby lze zdroj zpřesnit uvedením např. stránky či kapitoly, jež se uvádí za číslem záznamu (po čárce a ještě před uzavírající hranatou závorkou). V \LaTeX u lze využít nepovinný parametr příkazu `cite`.

Označení rozsahu se poněkud liší u přímých a nepřímých citací.

U přímých citací je označení rozsahu kritické. V případě citací, které jsou kratší než odstavec je nutné text vyznačit kurzívou a zahrnout do uvozovek. Odkaz musí následovat hned za označným textem.

U citací v rozsahu odstavce či více odstavců se využívá zvětšení okrajů na levé i pravé straně odstavců (viditelné na první pohled). V \LaTeX u lze použít prostředí `quote` nebo `quotation`. Text by měl být navíc v uvozovkách. Kurzíva je možná, ale u rozsáhlejších citací není příliš vhodná. Odkaz se umísťuje na konec posledního převzatého odstavce.

Speciální případ je možný v případě matematických definic a vět. Pokud jsou v rámci kapitoly převzaty jen z jediného zdroje, lze na počátku kapitoly uvést hromadný odkaz například v podobě věty: Všechny definice a věty uvedené v této kapitole jsou převzaty z [X].

V případě převzatých obrázků se odkaz umísťuje na konec popisku. Aby však bylo zřejmé, že se jedná o přímé převzetí (kurzívu ani uvozovky nelze použít) je nutné explicitně vyjádřit, že obrázek byl převzat ze zdroje bez podstatných změn například: (převzato z [X]) nebo (překresleno z [X]).

U nepřímých citací je vyznačování rozsahu volnější. Nejjednodušší je uvádění holé citace na konci vět (před tečkou) nebo konci odstavce (za poslední tečkou). V mnoha případech je ale možné citace uvádět explicitněji a stylistiky je provázet s okolním textem.

příklady:

- zajímavá alternativa je popsána v [x]
- údaj je převzat z [x]
- použití návrhového vzoru poprvé popsal N.N v [x]
- volně přeloženo z [x]
- řešení bylo navrženo uživatelem N v [x] (vhodné např. pro stackoverflow a podobné zdroje)

Explicitnější vyjádření je nutno použít i v případě, že rozsah citace přesahuje odstavec.

- následující příklad je převzat z [x]
- výčet vychází z [x] je však doplněn o ...

Teoreticky lze podobné řešení využít i u celých sekcí či kapitol (kapitola je zpracována na základě [x]). V tomto případě je však nutné předpokládat, že v dané kapitole není žádná autorská myšlenka, a že autor se nesnažil najít alternativní pohledy či zdroje (a hodnotit tak, lze pouze autorovu schopnost výběru informací či stylistiky).

Výjimečně lze uvádět i několik citací se shodným či překrývajícím se rozsahem např. *následující specifikace je převzata z [x] a [y]*. To je však tolerovatelné jen v případě, v kdy by oddělení oddělení zdrojů bylo obtížné nebo nepřehledné a spojení nepřináší problémy s intelektuálním vlastnictvím (mají stejného autora či copyright). Zcela nepoužitelné jsou v případě většího rozsahu citace (např. na úrovni sekcí či kapitol)!

V případě obrázků je vhodné uvést explicitnější specifikaci, jak byl originální obrázek pozměněn resp. rozšířen.

Příklad:

- (převzato z [x] a doplněno)
- (převzato z [x], přeloženo)
- (upraveno z [x] pro novou verzi technologie ...)
- (inspirováno diagramem [x])
- (viz také [x] pro data X)

5.2 Bibliografický záznam

Bibliografický záznam je datová struktura, jenž má dvě základní funkce:

1. jednoznačné identifikování zdroje
2. určení primární odpovědnosti (typicky je to autor resp. autoři, u webových zdrojů to však často bývá korporace).

Pro každý typ zdrojového dokumentu (zdroje) existuje množina klíčových atributů, které by měly být specifikovány (ne zcela vhodně označované jako povinné) a další, které hrají jen pomocnou roli.

V praxi však může nastat situace, kdy není zřejmé, jaký typ dokumentu pro daný zdroj zvolit resp. nelze zjistit hodnoty klíčových atributů. V tomto případě je nutné improvizovat a snažit se, aby záznam plnil v maximální míře obě funkce.

Struktura bibliografického záznamu je v zásadě dána těmito dimenzemi:

médium – základní dělení je na tištěné dokumenty a online dokumenty (dokumenty na elektronických nosičích tvoří jakási přechod mezi oběma typy dokumentů)

samostatnost – zdroj může být samostatný nebo součást rozsáhlejšího zdroje

periodičnost – periodický dokument vychází po jednotlivých částech, přičemž počet částí není předem znám (např. časopis).

Tištěné samostatné dokumenty neperiodické

Typickým příkladem samostatného tištěného dokumentu je kniha či monografie.

Základním zdrojem informací pro bibliografický záznam u knih je tzv. tiráž, tj. soupis vydavatelských údajů uvedený na konci knihy či na stránce za titulem. Využít lze i další zdroje (např. katalogy knihoven či knižní e-shopy, bibliografické záznamy v jiných dokumentech), ale v tomto případě je nutné provádět kontrolu, neboť tyto sekundární zdroje často obsahují chyby.

klíčové atributy:

ISBN : ISBN je celosvětový jedinečný identifikátor neperiodických tištěných dokumentů. Pokud ho kniha má, pak je dokument jednoznačně identifikován (a další identifikace už hraje jen sekundární roli). Pomlčky v ISBN nejsou součástí identifikátoru a lze je vynechávat (i když občas se jedno ISBN přiděluje více svazkům). Navíc existují ve dvou podobách ISBN-10 s deseti číslicemi a ISBN-13 s třinácti. Pokud jsou k dispozici oba je vhodnější uvádět ISBN-13 (i když ISBN-10 lze snadno mapovat na ISBN-13).

název : název knihy je povinný údaj a měl by být vždy vyplněn. Použit by měl být vždy originální název bez úprav. Jedinou přípustnou úpravou je změna velkých písmen (verzálék) na malá, které by mělo odpovídat pravidlům příslušného jazyka.

podnázev : některé knihy mají i podnázev Někdy je těžké rozeznat, co je název a podnázev. Zde platí pravidlo, že název by neměl obsahovat dvojtečku, tečku, středník apod. Od podnázvu je potřeba odlišit název edice. Podnázev je nepovinný (doporučuji uvádět pokud obsahuje klíčové informace).

autoři : v bibliografickém záznamu by měli být uvedeni všichni primární autoři (tj. není potřeba uvádět překladatele, ilustrátory, apod.)

vydání : označení konkrétního vydání. Je důležité především tehdy, když není známo ISBN a existuje více odlišných vydání (s různým obsahem)

nakladatel : uvádí se jméno nakladatelství, a to především z důvodů odpovědnosti

místo vydání : uvádí se jméno města, popřípadě stát, především tehdy pokud není jednoznačné (např. Cambridge) a to ve stručné podobě (např. stačí *United Kingdom*). Podobně stručný by měl být název nakladatelství (tj. bez označení typu společnosti, apod., rodičovské společnosti, apod.) V dnešní době globalizace je tento údaj v mnoha případech nevýznamný (tj. ho lze vynechat, především tehdy pokud je nakladatelství neznámé).

rok vydání : rok vydání přesněji identifikuje dokument. Pokud ho nelze zjistit, lze jej nahradit rokem copyrightu (v tomto případě je uvozen znakem c např. c2022)

edice : kniha může být vydána v rámci edice. Edici doporučuji neuvádět, výjimkou jsou edice, které jsou všeobecně známe.

URL : uvádí se pouze v případě, že je kniha dostupná online a to oficiálně a bez poplatků. Uvedení URL v tomto případě usnadňuje její získání (v tomto případě je ale často lepší citovat ji jako elektronickou knihu).

příklad:

Následující biblografický záznam byl získán z katalogu systému knihovny UJEP (volba Citace Pro v dolní části výpis záznamu).

RASCHKA, Sebastian a Vahid MIRJALILI. *Python machine learning: machine learning and deep learning with Python, scikit-learn, and TensorFlow*. Second edition. Birmingham: Packt, 2017. Expert insight. ISBN 978-1-78712-593-3.

Tento záznam splňuje základní požadavky, neboť obsahuje údaje týkající se odpovědnosti i jednoznačnou identifikaci dokumentu (a to jak ISBN tak přesným určením vydání). Zahrnutí podnázvu je vhodné, neboť obsahuje dodatečné informace (jména frameworků). Nakladatelství je uvedeno ve stručné podobě (tj. *Packt*) je uvedeno ve stručné podobě. Nadbytečné je jen uvedení edice (*Expert insight*).

Online samostatné dokumenty neperiodické

Typickým příkladem je online PDF dokument (včetně elektronické knihy). Dalším příkladem je webové sídlo (*web site*) tj. typicky hierarchický systém více stránek (nikoliv tedy jedna konkrétní web strán).

medium : u online zdrojů se jako médium uvádí slovo *online*.

URL : klíčový údaj pro online zdroje. Některé systémy (např. Wikipedia) poskytují tj. fixní URL, které odkazují na konkrétní verzi dokumentu, resp. stránek. I když jsou tato URL obecně delší, je nutné jim dát přednost, neboť zaručují jedinečnost.

název : název nelze vynechat i když ne vždy je jasné, co je hlavním názvem. V tomto případě je možné využít obsahu elementu title v hlavičce HTML (pokud je zdroj v HTML) nebo jiná metadata (například jak je zdroj pojmenován v odkazu).

autoři : autor nebývá u mnoha online dokumentů dohledatelný (a v tomto případě je nutné ho vynechat). Rozhodně však věnujte čas zjištění autorství (může být uvedeno i mimo dokument).

odpovědná korporace : typicky je to držitel intelektuálních práv (copyrightu). Důležitý je především v případě, že není znám autor, ale uvádějte ho ve všech případech, kdy je dohledatelný. Většina bibliografických stylů tento atribut nepodporuje resp. ho běžně nezobrazuje. Proto je vhodné pro tento účel využívat atribut *nakladatel* (i když to není totéž).

verze/čas poslední aktualizace : nahrazuje rok vydání. V případě, že není použit fixní odkaz, je klíčovým zdrojem informací, jaká z verzí dokumentu byla použita jako zdroj. Online dokumenty se mění často, a tak je vhodné uvádět, co nejpřesnější specifikaci (číslo verze, čas poslední aktualizace). Jen v případě, že dokument není verzován a nelze zjistit přesnější čas poslední modifikace, lze využít vrocení (stejně jako u knih může být odhadnuto z copyrightu).

datum použití : je to povinný údaj i když důležitý je jen v případě, kdy nelze určit přesnější verzi. Měl by být v ISO formátu tj. ve tvaru RRRR-MM-DD. Toto datum běžně generuje editor bibliografických citací podle data vytvoření záznamu. V každém případě by mělo ležet v časovém intervalu od poslední modifikace zdroje (je-li uvedeno) do data odevzdání závěrečné práce.

příklad:

Dílčí tištěné dokumenty

U dílčích tištěných dokumentů je typické, že kromě identifikace dílčí části obsahují i identifikaci dokumentu jako celku.

Klasickým příkladem jsou články ve sborníku nebo vědeckém časopise. Kapitoly v knize (monografii) se citují, jen případě, že každou z nich vytvořil jiný autor (či kolektiv autorů)

V zásadě platí tato pravidla:

- uvádí se jen autoři dílčí části, nikoliv například editoři sborníku nebo časopisu
- uvádí se pozice části v celém dokumentu nejlépe pomocí rozsahu stránek
- pokud má dílčí část vlastní jednoznačný identifikátor (například DOI), není potřeba uvádět identifikátor knihy nebo periodika.

Dílčí online dokumenty

Tento typ citací se používá pro webové stránky, jež jsou součástí webového sídla například pro konkrétní stránky s dokumentací nebo dokumenty uložené na GitHubu. Pro jiné elektronické dokumenty, pokud nejsou výslovně součástí webového sídla (např. elektronického sborníku) je vhodnější použít záznam samostatného dokumentu (viz výše).

Název stránky je doplněn jménem webového sídla (to je typicky uvedeno v záhlaví každé stránky resp. na hlavní stránce webového sídla. Autoři se vztahují ke stránce zatímco korporátní odpovědnost je typicky vztažena k celému sídlu (pokud jsou známy autoři i korporátní odpovědnost je vhodné uvést oba údaje, vždy však musí být uveden alespoň jeden z těchto údajů). Všechny ostatní atributy se vztahují

příklady:

What's New In Python 3.9: Summary – Release highlights. *Python 3.9.0 documentation [online]*. Python Software Foundation, October 14, 2020 [cit. 2020-10-15]. Dostupné z: <https://docs.python.org/3/whatsnew/>

Záznam obsahuje název dílčí části a také název celého webového sídla (v kurzívě). Odpovědná organizace je uvedena na místě nakladatele (autor není uveden a tak je tato informace klíčová). Verze je určena datem poslední modifikace (je uvedeno přímo ve tvaru použitém na stránce). Datum citování je povinné, ale v tomto případě nenese žádnou přidanou informaci (jen to, že citace byla vytvořena jen den po poslední modifikaci. Poslední součástí je URL.

Python nonlocal statement. *Stack Overflow [online]*. Stack Exchange, 2022-03 [cit. 2022-07-27]. Dostupné z: <https://stackoverflow.com/questions/1261875/python-nonlocal-statement>

Struktura záznamu je stejná. Čas poslední modifikace byl určen z informace, že poslední modifikace proběhla před čtyřmi měsíci (je uvedena v ISO formátu, ale odpovídající by byl i údaj například ve tvaru *březen 2022* nebo *March 2022*).

5.3 Často kladené otázky

Co není potřeba citovat?

Obecně platí, že citovat není potřeba znalosti, které jste získali v průběhu studia a to jak při výuce tak i z učebních materiálů (opor, skript). Citovat není potřeba ani zdroj formálních údajů (např. významu zkratk), pokud je lze snadno získat (například na Wikipedii).

To jest není nutné uvádět citaci při uvedení zkratky HTTP (zkratka je všeobecně známá a běžně využívána v mnoha kurzech). Podobně není nutné odkazovat pojmy jako Internet, počítačová síť, programovací jazyk, procesor, apod.

Běžně se také necitují (původní) myšlenky vedoucího práce, pokud si vedoucí práce nevyžádá jinak. Pokud vám zprostředkuje nepůvodní myšlenku, měl by vám pomoci najít originální zdroj (který uvedete v citaci).

Citování není možné v případě, kdy není znám původní zdroj, resp. je v podobě, kterou není možné citovat (lidová říčení, apod.) Pravděpodobnost výskytu takových textů v informatické bakalářské práci je však velmi nízká.

Jak citovat informace z (podnikových) školení

Pokud se jedná o evidentní výtvar školitele, můžete odkazovat příslušný výukový materiál (i když je neveřejný). Pokud je informace nepůvodní, pak je vhodné citovat primární resp. alespoň dostatečně autoritativní zdroj.

Jak citovat ústní sdělení?

Ústní sdělení je potřeba citovat jen tehdy, když je od autoritativní osoby v oblasti její odbornosti. Pokud například píšete práci o nasazení databáze, pak je autoritativní osobou například správce databázového systému (který vám sdělí například zkušenosti s nasazením).

Jak je uvedeno výše, ve většině případů se necitují ústní sdělení učitelů, školitelů, vedoucího práce a dalších sekundárních zdrojů.

Pokud citujete ústní sdělení je vhodné s tím danou osobu seznámit či získat alespoň neformální souhlas, neboť sdělené informace nemusí být veřejné.

Navzdory důležitosti ústních sdělení v některých typech prakticky zaměřených prací, není citace ústních sdělení standardizována. Jednoduchý návod nabízí například blog na citace.com [XXX].

Ústí sdělení je však neověřitelné a nelze ho jednoznačně identifikovat. Proto je lepší pokud se sdělení děje například e-mailem. Citace e-mailové komunikace i dalších netradičních zdrojů shrnuje dokument [XXX].

Je možno citovat Wikipedii?

Citování Wikipedie se obecně nedoporučuje, neboť se jedná o terciární zdroj (encyklopedia vytvořená na základě druhotných informací) a její kvalita je značně kolísavá.

Na druhou stranu Wikipedia (především v anglické verzi) často obsahuje i hodnotný a jinak jen obtížně dostupný materiál, a tak nelze citování z Wikipedie striktně zakázat.

Základní doporučení pro citování z Wikipedie:

- citujte jen tehdy, pokud nemáte k dispozici primární zdroje (ty jsou často odkazovány přímo z Wikipedie)
- citujte jen kvalitní články (které nejsou označeny jako problematické), které se v oblasti informatiky a matematiky objevují spíše na anglické Wikipedii
- citace z Wikipedie by měly tvořit jen malou část zdrojů (typicky méně než 10

Z Wikipedie rozhodně necitujte články věnované běžně známým technologiím a poznatkům, které jsou běžnou součástí kurzů.

6 Zhodnocení

7 Závěr

Závěr je klíčovou kapitolou, která může nejvíce ovlivnit vaši obhajobu. Základní částí závěru je přehledné shrnutí výstupů práce tj. co jste udělali pro dosažení cílů práce. Je nutné se vyhnout hodnocení, zda tím byli splněny cíle práce, či nikoliv (to je úkol posudků a především komise).

A Externí přílohy

Externí přílohy této bakalářské práce jsou umístěny na adrese:

https://github.com/Jiri-Fiser/thesis_ki_ujep.

Na úložišti GitHub mohou být uloženy tyto externí přílohy:

- **zdrojové kódy**
- **doplňkové texty** (například jak instalovat aplikaci, manuály aplikace)
- **schémata** (především, pokud se nevejdou na stranu A4 a jejich vytištění je tak problematické)
- **screenshoty** (v textu práce lze použít jen omezený počet snímků obrazovky, které navíc nemusí být při černobílém tisku příliš přehledné)
- **videa** (například ovládání aplikace)

V každém případě by to však měli být pouze materiály, které jste vytvořili sami. Materiály jiných autorů uvádějte v seznamu použité literatury (včetně případných odkazů na jejich originální umístění).

V této kapitole stačí uvést pouze základní strukturu úložiště (co se kde nalézá a jakou má funkci) například v podobě tabulky.

ki-thesis.pdf	text práce v PDF
ki-thesis.tex	zdrojový kód práce v \LaTeX
kitheses.cls	definice třídy dokumentů (rozšířená třída scrbook)
thesis.bib	bibliografická databáze (exportována z citace.com)
LOGO_PRF_CZ_RGB_standard.jpg	logo fakulty s českým textem
LOGO_PRF_EM_RGB_standard.jpg	logo fakulty s anglickým textem

Všechny tyto soubory jsou potřeba pro překlad dokumentu (logo stačí jedno v příslušné jazykové verzi).

B Další přílohy

Výjimečně může práce obsahovat i další tištěné přílohy. Obecně však dávejte přednost elektronickým přílohám umístěným na GitHubu (tato kapitola tak bude úplně chybět).